

# **MBA Executivo em Business Analytics e Big Data**

## **Análise de Séries Temporais**

**Turma:** MSP12013-TBABD-T2

### ***Trabalho Final***

**Professor:**

Rafael Scopel Silva

**Alunos:**

Ana Melo - A57754853

Daniele Lyra - A55222100

**Outubro 2020**

## Índice

1. Contexto e Objetivo do Caso Estudo .....	3
2. Característica da Série Temporal.....	4
3. Preparação Dados Treinamento e Teste .....	5
4. Estimativa e Teste de Modelos .....	6
4.1. Modelo Naive .....	6
4.2. Modelo Tendência Linear .....	7
4.3. Modelo Tendência Quadrática .....	8
4.4. Modelo Média Móvel .....	10
4.5. Modelo Suavização Simples .....	11
4.6. Modelo Suavização Tendência Aditiva.....	12
4.7. Modelo Suavização Tendência Multiplicativa .....	14
4.8. Modelo Suavização – Seleção Automática .....	15
4.9. Modelo ARIMA .....	17
4.9.1. Estacionando Série Temporal.....	17
4.9.2. Execução Manual Arima .....	18
4.9.3. Execução Auto Arima.....	20
5. Seleção de Modelo.....	21
6. Conclusão .....	21

## 1. Contexto e Objetivo do Caso Estudo

Uma empresa possui serviços de Cloud, tanto infraestrutura quanto plataforma como serviço, IaaS e PaaS. Ambas soluções são comercializadas através do mesmo Código de produto, créditos universais, para flexibilizar a adoção dos serviços de nuvem pelos clientes.

Os clientes podem adquirir créditos de nuvem em dois modelos: Compromisso de Consumo ou Pago conforme uso.

No modelo de *Compromisso de Consumo* os clientes compram pacotes de créditos, por um prazo mínimo de um ano. No momento da compra o cliente definiu o quanto de crédito ele deve consumir a cada mês. Exemplificando, um cliente comprou 10 créditos por mês, mas utilizou 12 num dado mês, nesse período ele terá utilizado 10 créditos e gerado overage de 2. Outro exemplo, é se esse mesmo cliente utilizar somente 8 créditos em outro mês, nesse caso ele vai deixar expirar 2 créditos no período.

No outro modelo comercial, *Pago Conforme o Uso* não tem as figuras de pacote, overage ou expirado ele apenas tem créditos utilizados no período.

O Consumo total de cada período é o total de créditos utilizados mais overage.

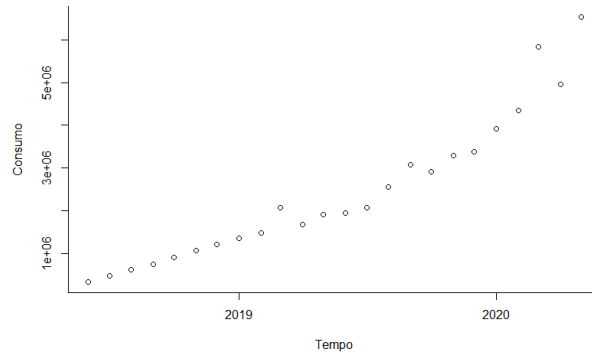
Abaixo, temos a planilha de consumo de todos os clientes no período de 2 anos:

Período	Pacote	Utilizado	Overage	Expirados	Total
01/06/2018	1.292.292,14	327.067,89	5.818,74	965.224,10	332.886,63
01/07/2018	1.531.259,66	444.324,31	24.484,92	1.086.935,35	468.809,24
01/08/2018	1.766.091,92	575.283,45	31.432,08	1.190.808,46	606.715,53
01/09/2018	2.121.284,30	701.021,86	40.902,79	1.420.262,44	741.924,65
01/10/2018	2.237.005,12	866.892,83	43.349,21	1.370.112,30	910.242,03
01/11/2018	2.379.787,92	1.007.147,26	51.936,95	1.372.640,53	1.059.084,21
01/12/2018	2.785.679,59	1.128.729,89	86.158,15	1.645.429,65	1.214.888,04
01/01/2019	2.984.317,13	1.283.452,83	74.254,02	1.690.887,32	1.357.706,86
01/02/2019	3.103.275,38	1.354.788,51	119.880,82	1.736.402,31	1.474.669,33
01/03/2019	5.046.868,63	2.001.676,85	74.519,57	3.037.227,84	2.076.196,42
01/04/2019	3.490.912,08	1.546.070,24	127.112,34	1.934.620,73	1.673.182,58
01/05/2019	4.444.525,67	1.775.566,96	124.669,47	2.638.193,37	1.900.236,43
01/06/2019	3.942.406,19	1.741.712,95	197.944,15	2.192.729,29	1.939.657,10
01/07/2019	5.121.527,15	1.911.211,52	154.160,92	3.198.756,92	2.065.372,44
01/08/2019	4.884.933,32	2.294.881,15	254.100,02	2.582.088,22	2.548.981,18
01/09/2019	4.909.682,70	2.807.203,04	273.928,85	2.093.610,72	3.081.131,89
01/10/2019	4.814.143,04	2.574.497,62	332.412,89	2.227.863,32	2.906.910,51
01/11/2019	5.345.176,70	2.873.901,92	411.878,14	2.450.440,08	3.285.780,06
01/12/2019	6.001.229,70	2.966.032,25	410.497,31	3.014.362,75	3.376.529,56
01/01/2020	5.495.944,85	3.313.070,42	597.471,86	2.162.039,48	3.910.542,28
01/02/2020	6.972.561,41	3.837.628,88	510.326,61	3.111.628,09	4.347.955,49
01/03/2020	7.919.797,19	5.041.895,67	792.605,76	2.825.184,37	5.834.501,43
01/04/2020	6.691.762,23	4.386.588,04	561.634,39	2.233.575,61	4.948.222,42
01/05/2020	8.719.150,94	5.386.841,15	1.146.422,29	1.122.884,96	6.533.263,44

Nesse estudo, vamos entender o comportamento do consumo dos créditos de nuvem pelos clientes ao longo do tempo e avaliar o modelo acurado para gerar o forecast de consumo.

## 2. Característica da Série Temporal


Primeiramente plotamos um gráfico de dispersão entre o total de Consumo e tempo.



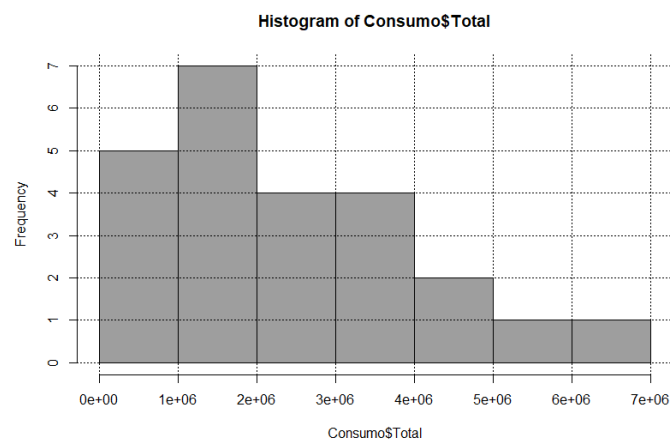
Como podemos ver na tabela acima essa amostra não apresenta consumo nulo e abaixo está a estatística descritiva do total de consumo:

Min.	1st Qu	Median	Mean	3rd Qu	Max.	Ampl.	Std
332.887	1.175.937	2.002.515	2.441.475	3.308.467	6.533.263	6.200.377	1.699.466


Geramos o Bloxplot que não indicou a existência de outliers:



E o histograma apresentou uma curva com desvio a esquerda, mas novamente sem indícios de outliers.



Transformamos os dados do total de consumo em uma série temporal, gerando a curva abaixo, onde visualmente podemos notar uma tendência e que não há sazonalidade. Com isso, iremos focar o estudo do melhor modelo a essa característica dos dados.

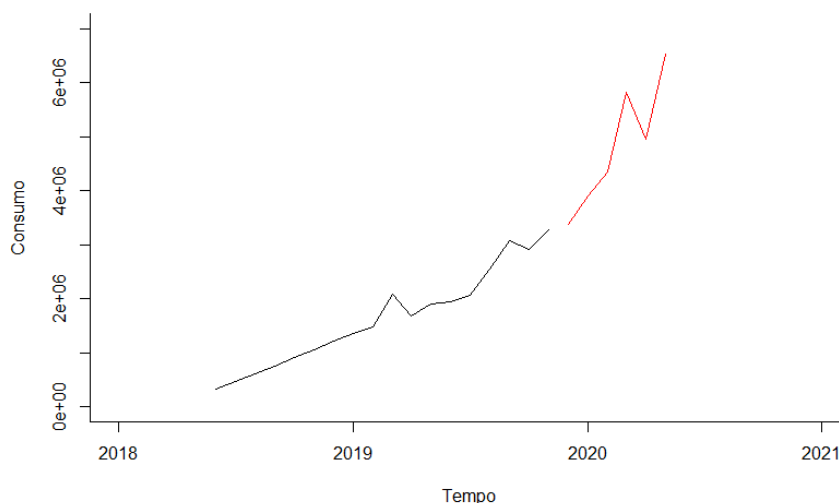


### 3. Preparação Dados Treinamento e Teste

O histórico de consumo possui 24 amostras, iremos reservar 18 meses para treinamento dos modelos e 6 meses para testes.

Portanto, a base de treinamento será o período de Junho de 2018 até Novembro de 2019 e a base de teste será entre os meses de Dezembro de 2019 a Maio de 2020.

Dessa forma, a base de treinamento irá representar 75% do conjunto dos dados.



## 4. Estimativa e Teste de Modelos

### 4.1. Modelo Naive

Iniciamos a nossa avaliação com os modelos mais básicos e simples.

O modelo Naive pega o último valor da amostra de treinamento e mantém para os períodos futuros. Abaixo, podemos ver que para a nossa amostra de teste foi: 3.285.780.

```
Forecast method: Naive method

Model Information:
Call: naive(y = treinamento_cs, h = cs_amostra_teste, level = 0)

Residual sd: 241844.3421

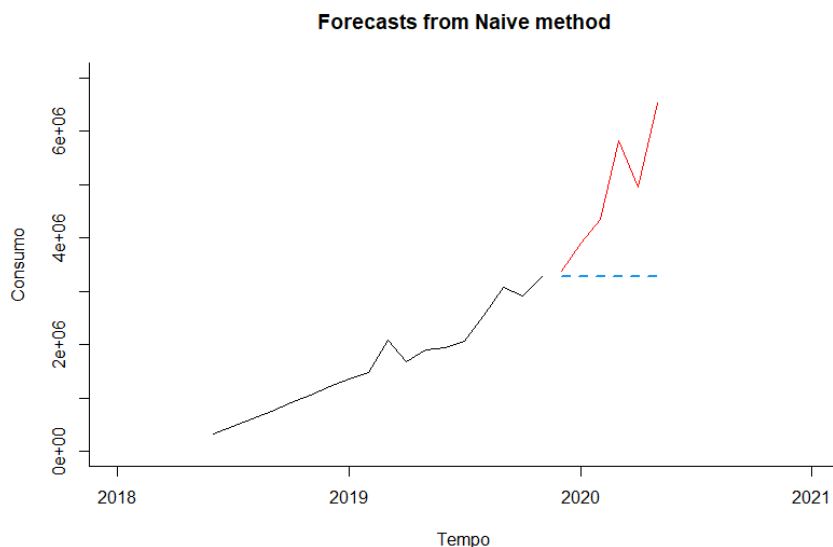
Error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 173699.6 291924.2 241609.6 11.79427 15.3331 0.1238159 -0.4237545

Forecasts:
      Point Forecast      Lo 0      Hi 0
Dec 2019      3285780 3285780 3285780
Jan 2020      3285780 3285780 3285780
Feb 2020      3285780 3285780 3285780
Mar 2020      3285780 3285780 3285780
Apr 2020      3285780 3285780 3285780
May 2020      3285780 3285780 3285780
```

Quando realizados fazemos um teste de acurácia dos dados da amostra de teste encontramos o Erro Médio Absoluto Percentual (MAPE) de 28,35%.

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1	Theil's U
Training set	173699.6	291924.2	241609.6	11.79427	15.33310	0.1238159	-0.4237545	NA
Test set	1539389.0	1885586.7	1539389.0	28.34677	28.34677	0.7888794	0.2268889	1.854718

Abaixo temos o gráfico composto pela base de treinamento, teste e o modelo previsto:



Começamos essa avaliação pelo Naive, pois como ele só replica o último valor esse seria o custo de “não fazer nada”. Para implementarmos um modelo mais sofisticado precisamos ter um MAPE menor do que obtivemos com o modelo Naive.

## 4.2. Modelo Tendência Linear

O modelo linear apresentou o  $R^2$  de 95,74%, portanto um alto poder preditivo na amostra.

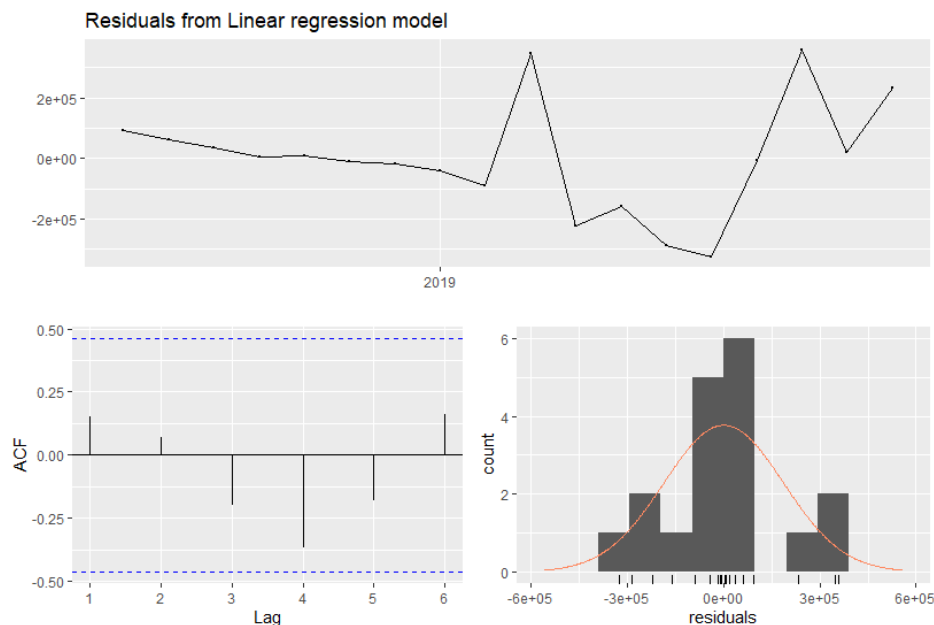
```
Call:
tslm(formula = treinamento_cs ~ trend)

Residuals:
    Min       1Q   Median       3Q      Max
-326200 -77371  -1457   56110  358599

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   74845     94471    0.792    0.44
trend       165481     8728   18.961 2.18e-12 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 192100 on 16 degrees of freedom
Multiple R-squared:  0.9574,    Adjusted R-squared:  0.9547
F-statistic: 359.5 on 1 and 16 DF,  p-value: 2.175e-12
```


Quando avaliamos os resíduos não vemos nem tendência nem sazonalidade nos ruídos, não estouramos o limite de confiança do ACF e a distribuição dos resíduos também não tem um comportamento muito destoante de uma distribuição normal.



No caso no modelo linear, ele apresenta uma melhoria do MAPE em relação ao Naive, com a redução na amostra de teste para 22,07%.

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1	Theil's U
Training set	6.462781e-12	181120.2	128941.6	1.150718	8.261183	0.06607775	0.15366340	NA
Test set	1.192493e+06	1457894.4	1192493.2	22.071319	22.071319	0.61110818	0.07322778	1.450736

Abaixo temos o gráfico com os dados de treinamento, teste e o modelo previsto, como podemos observar o modelo os valores projetados ficaram bem abaixo dos valores observados. O modelo não conseguiu capturar muito bem a estrutura dos dados, apenas uma pequena parte deles ficaram dentro do túnel de projeção e o resto a projeção foi bem distante.



### 4.3. Modelo Tendência Quadrática

O modelo quadrático melhorou o  $R^2$  para 96,5%, melhorando seu poder preditivo na amostra.

```
Call:
tslm(formula = treinamento_cs ~ trend + I(trend^2))

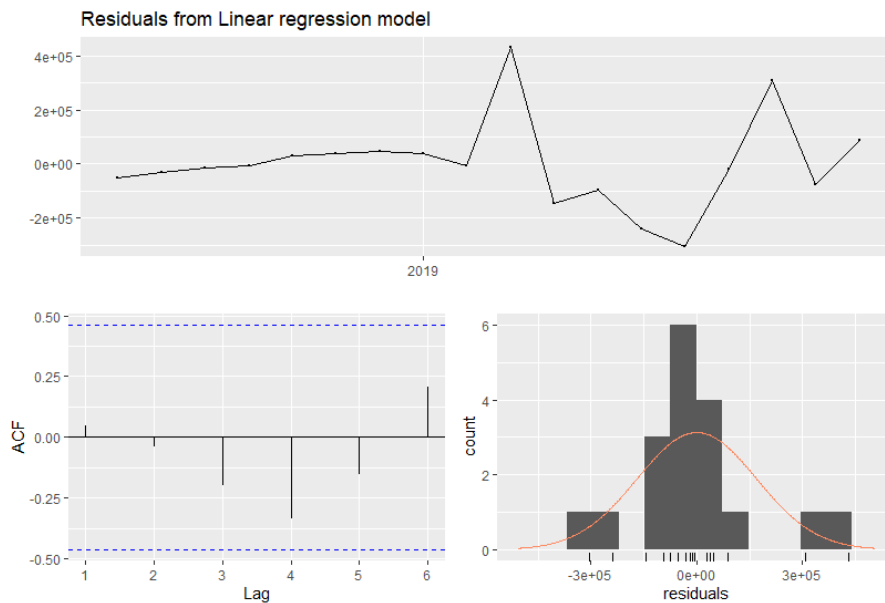
Residuals:
    Min       1Q   Median       3Q      Max
-304957 -68899  -9446   37971  431516

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  276647    142792   1.937  0.07176 .
trend       104940     34603   3.033  0.00839 **
I(trend^2)     3186       1770   1.801  0.09191 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 179900 on 15 degrees of freedom
Multiple R-squared:  0.965,    Adjusted R-squared:  0.9603
F-statistic: 206.6 on 2 and 15 DF, p-value: 1.213e-11
```



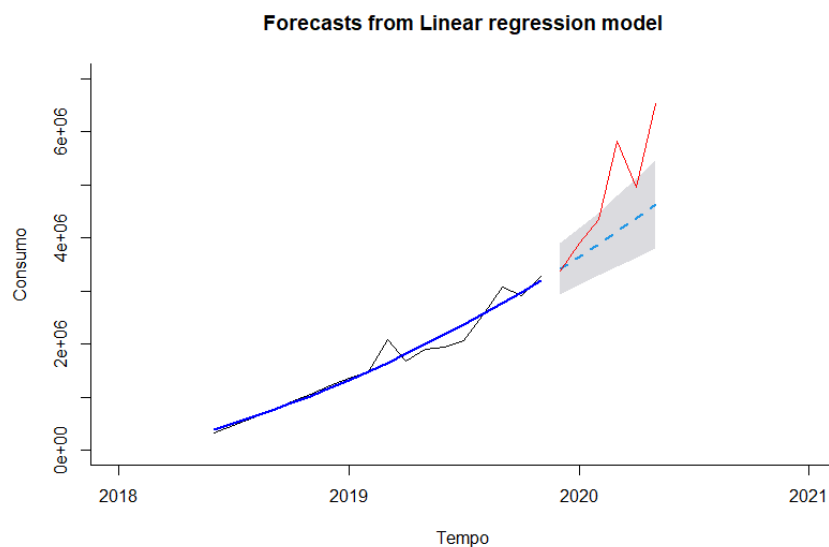
Fazendo uma análise dos resíduos ainda conseguimos notar alguma melhora no modelo quadrático, porém ainda não temos resíduos com distribuição normal.



Houve uma melhora no MAPE de teste para 14,76% (melhor anteriormente de 22%).

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1	Theil's U
Training set	1.293661e-11	164239.3	109063.0	-1.239108	6.46148	0.05589071	0.04572361	NA
Test set	8.101311e+05	1091284.9	824880.2	14.322484	14.75930	0.42272029	-0.03872544	1.087975


Abaixo temos o gráfico com os dados de treinamento, teste e modelo previsto, a projeção melhorou um pouco em relação ao anterior. O modelo conseguiu capturar um pouco melhor a tendência da série, entretanto continua não conseguindo capturar toda a estrutura dos dados, como pode ser visto os picos da série ficaram fora do túnel de projeção.



#### 4.4. Modelo Média Móvel

Desse ponto em diante iremos avaliar os modelos mais baseados na estrutura dos dados.

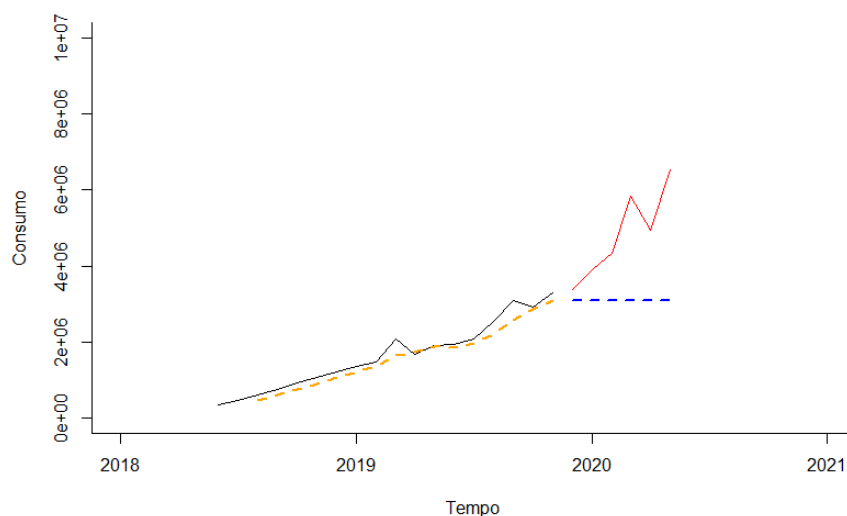
Primeiramente calculamos a média simples e a centrada de toda o conjunto de dados, agrupando a cada 3 meses para avaliar o resultado em relação aos dados originais.



Nesse caso, podemos notar que houve uma piora do MAPE para 32% (melhor modelo próximo a 15%):

	ME	RMSE	MAE	MPE	MAPE	ACF1	Theil's U
Test set	1733895	2047464	1733895	32.58837	32.58837	0.2268889	2.02216

Podemos ver no gráfico, que o distanciamento entre os valores estimados no modelo e os valores de validação. A projeção dos valores do modelo ficou muito distante dos valores observado, além de não ter capturado o componente de tendência da série.



## 4.5. Modelo Suavização Simples

Agora vamos avaliar alguns modelos de suavização. Para esses modelos a estimativa é feita por máxima verossimilhança, com isso não referenciamos o  $R^2$ , passaremos a avaliar o AIC, AICC e BIC. Na combinação ANN que é sem tendência, sem sazonalidade e erro aditivo para o modelo. Os parâmetros de avaliação do modelo obtidos estão em torno de 516, sendo este um valor alto o que nos indica que ainda não temos um modelo adequado.

```
Call:
ets(y = treinamento_cs, model = "ANN")

Smoothing parameters:
  alpha = 0.9846

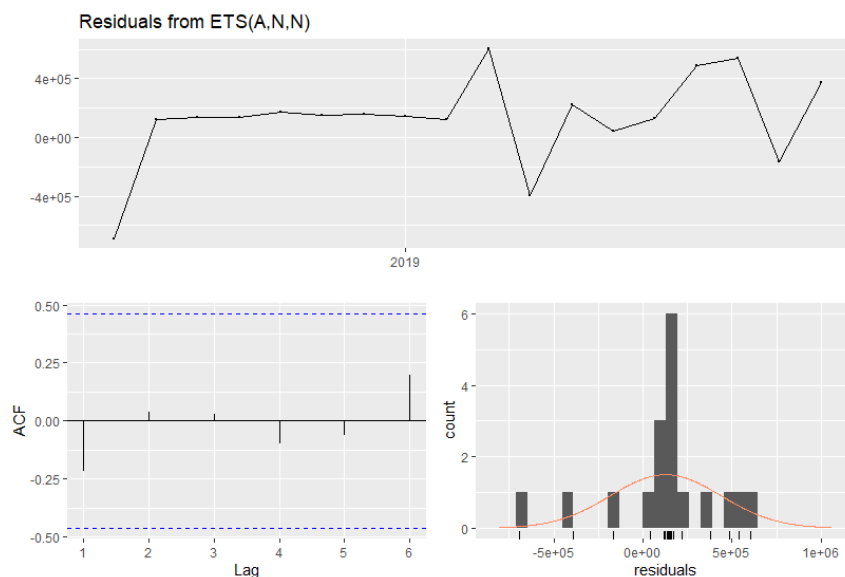
Initial states:
  l = 1023564.0175

sigma: 346884.8

      AIC      AICC      BIC
515.1495 516.8638 517.8206

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 127317.3 327046.1 266240.8 -0.3653752 25.93686 0.1364385 -0.2146975
```

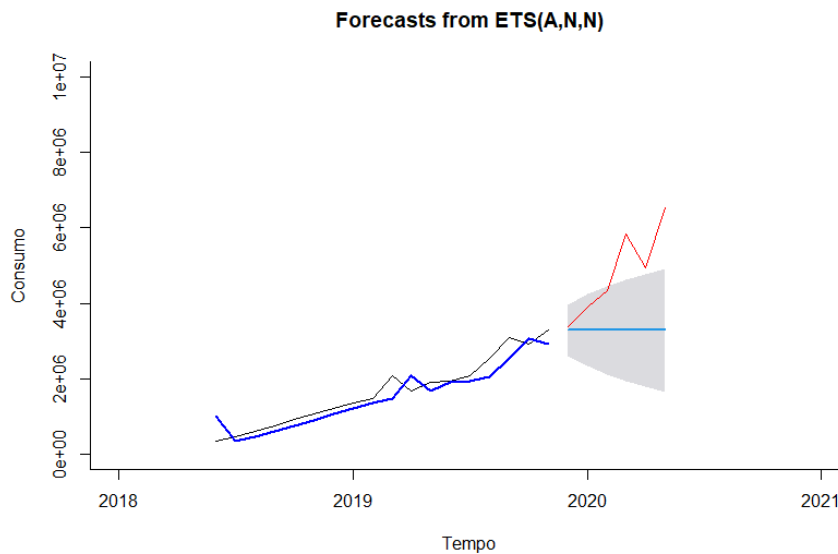
Nossos resíduos seguem sem padrões e sem violar os limites de confiança:



Nosso MAPE foi de 28,47%, não sendo o melhor modelo calculado até o momento:

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1	Theil's U
Training set	127317.3	327046.1	266240.8	-0.3653752	25.93686	0.1364385	-0.2146975	NA
Test set	1545183.9	1890320.6	1545183.9	28.4731378	28.47314	0.7918490	0.2268889	1.859635

E visualmente no gráfico, confirmamos que o modelo não é o mais adequado para o nosso conjunto de dados:



#### 4.6. Modelo Suavização Tendência Aditiva

O novo modelo com a combinação AAN, considerando agora uma tendência e erro aditivos, e sazonalidade neutra. Com isso, os parâmetros de avaliação AIC, AICc e BIC reduziram para valores próximos a 502, o que demonstra uma melhora da adequação do modelo ao conjunto de dados observados.

```
ETS(A,A,N)

Call:
ets(y = treinamento_cs, model = "AAN")

Smoothing parameters:
  alpha = 0.0507
  beta  = 1e-04


Initial states:
  l = 89196.2869
  b = 170020.6649

sigma: 215669.3

      AIC      AICC      BIC
499.6371 504.6371 504.0890

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -40649.38 190202.5 144033.7 -2.130099 8.912072 0.07381186 0.1582057
```

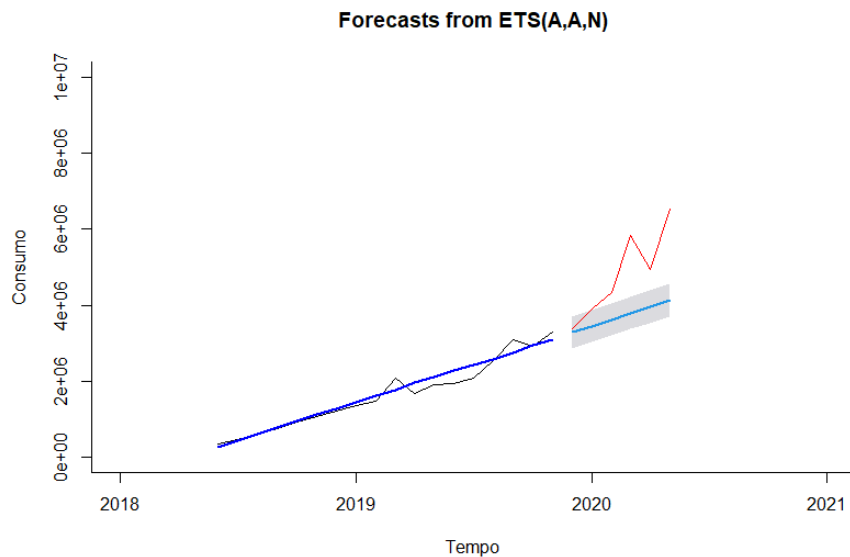
Os resíduos seguem sem nenhum ponto de atenção:



O MAPE ficou em 20,50%, melhor que na suavização simples, mas ainda não superando o modelo quadrático.

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1	Theil's U
Training set	-40649.38	190202.5	144033.7	-2.130099	8.912072	0.07381186	0.15820573	NA
Test set	1118505.76	1394154.3	1118505.8	20.492674	20.492674	0.57319240	0.06749106	1.38577

Finalmente, o gráfico confirma visualmente o resultado estatístico acima:



## 4.7. Modelo Suavização Tendência Multiplicativa

Evoluímos para avaliar a tendência multiplicativa, podemos notar uma singela piora no AIC, AICc e BIC.

```
ETS(M,Md,N)

call:
ets(y = treinamento_cs, model = "MMN")

Smoothing parameters:
  alpha = 0.846
  beta  = 0.0091
  phi   = 0.8

Initial states:
  l = 156540.9296
  b = 2.0314

sigma: 0.157

      AIC      AICc      BIC
499.9233 507.5597 505.2655

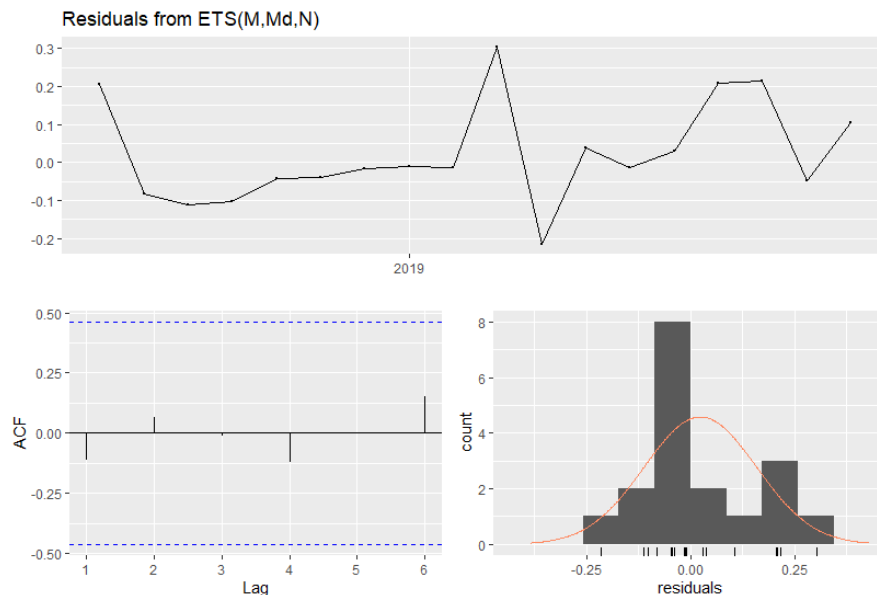
Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 55570.27 245646.9 163321.8 0.6804534 9.48774 0.08369634 -0.144498
> #verifica os resíduos com teste de Ljung-Box
> checkresiduals(modelo_ses_tm, test="LB")

Ljung-Box test

data: Residuals from ETS(M,Md,N)
Q* = 2.7381, df = 3, p-value = 0.4338

Model df: 5. Total lags used: 8
```

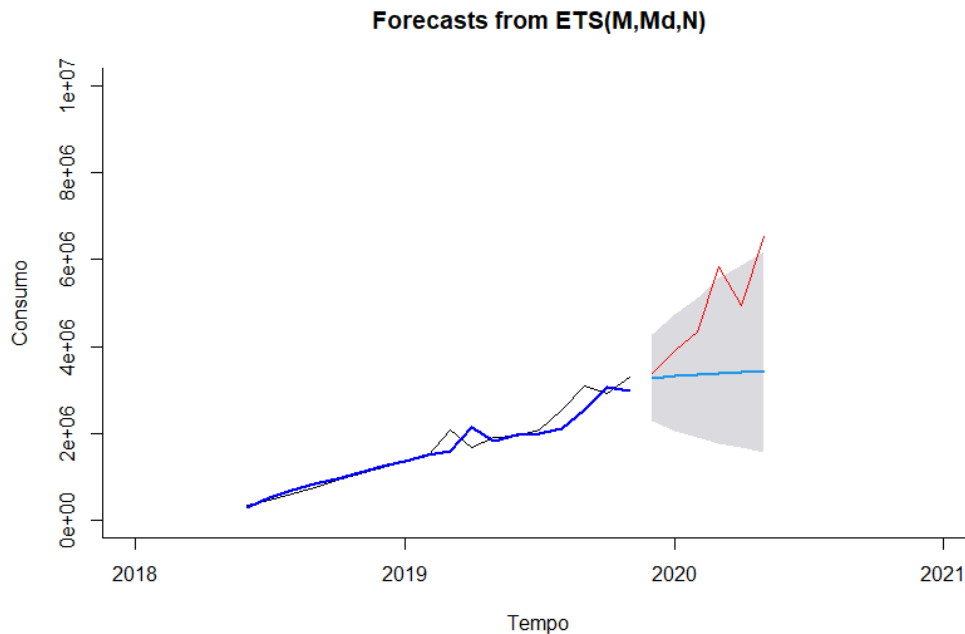
Os resíduos seguem sem trazer nenhum ponto diferente de atenção a ser considerado:



Podemos notar uma piora do MAPE no modelo multiplicativo em relação ao aditivo:

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1	Theil's U
Training set	55570.27	245646.9	163321.8	0.6804534	9.48774	0.08369634	-0.1444980	NA
Test set	1466275.48	1800795.8	1466275.5	26.9765588	26.97656	0.75141138	0.2067109	1.772613

Na visão gráfica, podemos notar que esse modelo tem um intervalo de confiança maior, os valores de validação ficam mais dentro deste intervalo, mas ainda violam o limite e a projeção fica muito distante dos dados observados.



#### 4.8. Modelo Suavização – Seleção Automática

Finalmente, decidimos rodar o modelo de suavização exponencial usando o otimizador de modelos da função ETS, com erro multiplicativos e tendência aditiva. Os resultados obtidos reforçam a avaliação que havíamos feito anteriormente, onde os indicadores (AIC, AICc e BIC) nenhum deles chegou a 500.

```
ETS(M,A,N)
call:
ets(y = treinamento_cs, model = "ZZZ", restrict = FALSE, allow.multiplicative.trend = TRUE)

Smoothing parameters:
  alpha = 0.1531
  beta  = 1e-04

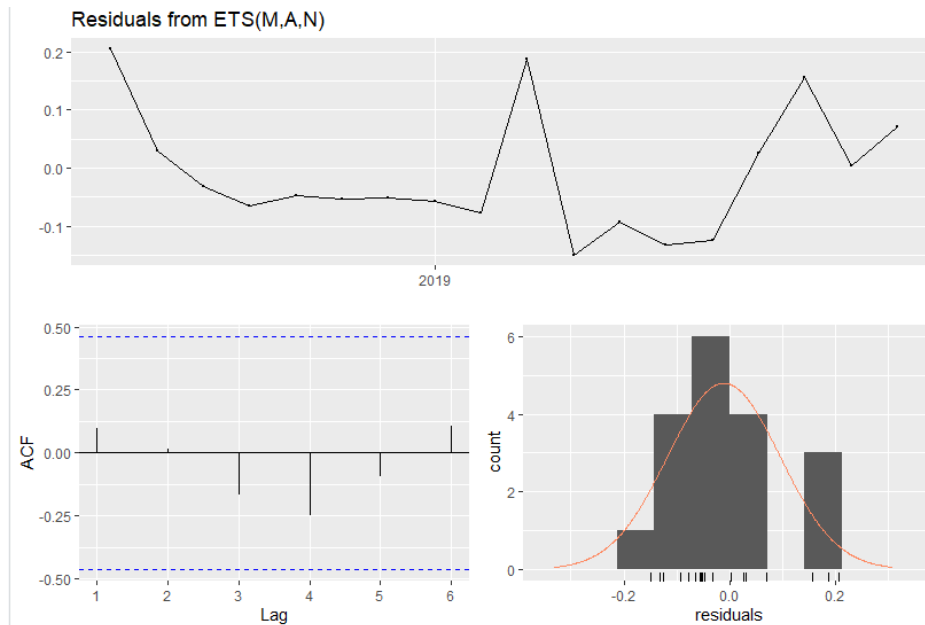
Initial states:
  l = 106197.8082
  b = 170021.0829

sigma: 0.1179

      AIC      AICc      BIC
490.0623 495.0623 494.5142

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set -23168.6 192725.9 146198.7 -2.17698 8.710538 0.07492137 0.1316648
```


Seguimos com resíduos que não geram nenhum ponto de atenção:



Obtivemos uma singela melhoria no MAPE ao considerar os erros multiplicativos:

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1	Theil's U
Training set	-23168.6	192725.9	146198.7	-2.17698	8.710538	0.07492137	0.13166480	NA
Test set	1128124.7	1401855.8	1128124.7	20.70268	20.702683	0.57812174	0.06744974	1.39376

Nesse caso, apresentamos um túnel menor do que na tendência multiplicativa, e maior que cenário onde os erros e tendência eram aditivos, realmente se mostrando o melhor modelo de suavização.



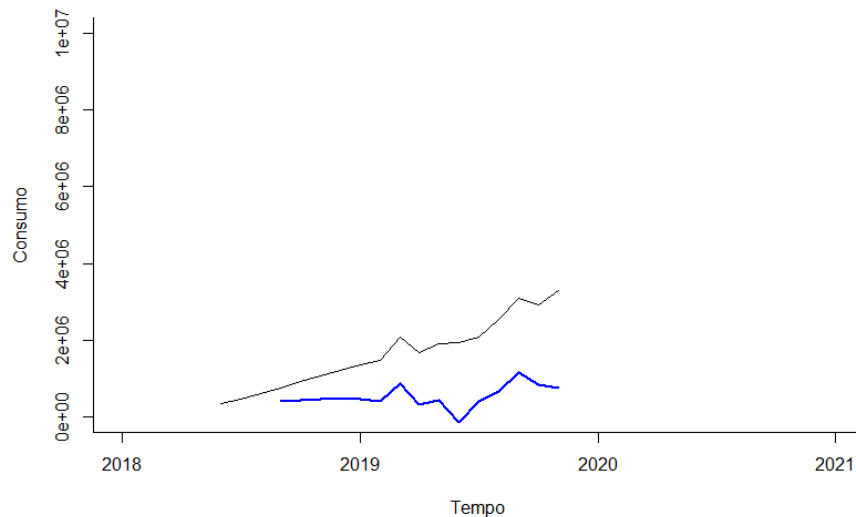


## 4.9. Modelo ARIMA

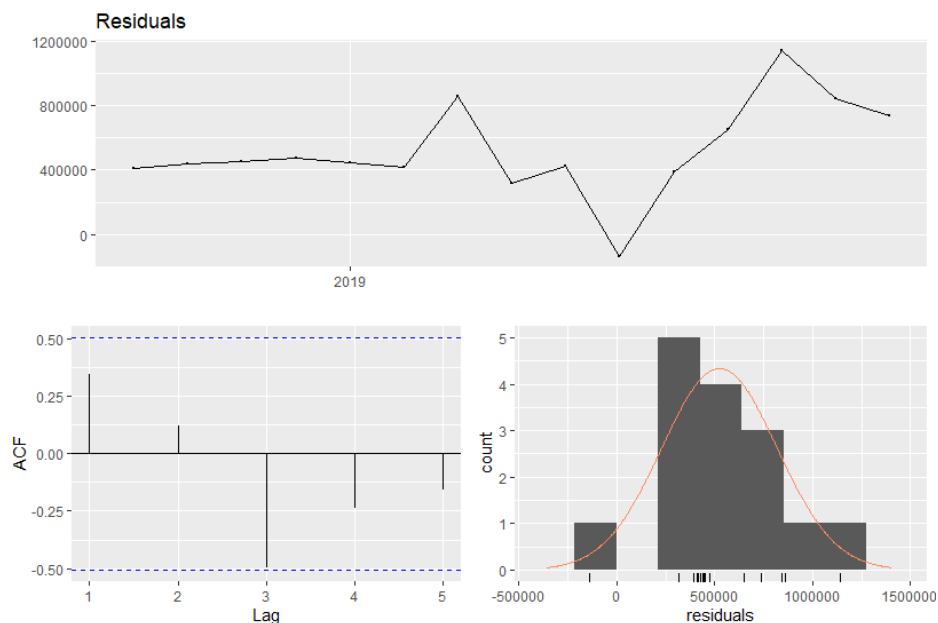
### 4.9.1. Estacionando Série Temporal

Fizemos alguns testes de diferenciação, avaliando os resíduos gerados e os testes KPSS e ADF para validar se a série ficou estacionária, o melhor resultado se apresentou com lag = 3.

Abaixo na visão gráfica notamos que a tendência foi retirada da série.



Os resíduos não apresentam nenhum fator visual demonstrando que ainda temos padrões nos resíduos.



O teste de Box-Ljung se mostrou estatisticamente relevante:

```
Box-Ljung test
data: cs_diff
X-squared = 2.2112, df = 1, p-value = 0.137
```

Pelo teste de KPSS não refutamos a hipótese de estacionariedade.

```
#####
# KPSS Unit Root Test #
#####

Test is of type: mu with 2 lags.

Value of test-statistic is: 0.1999

Critical value for a significance level of:
10pct 5pct 2.5pct 1pct
critical values 0.347 0.463 0.574 0.739
```

E novamente pelo teste de Dickey-Fuller refutamos a hipótese de não estacionariedade.

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####

Test regression none

Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)

Residuals:
    Min       1Q   Median       3Q      Max
-503374 -80550   7896  344855  610059

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
z.lag.1      -0.05697    0.17457  -0.326   0.750
z.diff.lag  -0.31328    0.30586  -1.024   0.328

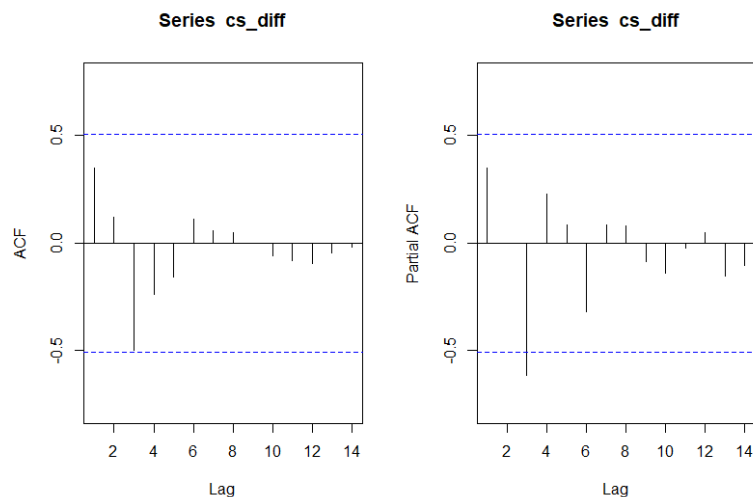
Residual standard error: 346000 on 11 degrees of freedom
Multiple R-squared:  0.1315,    Adjusted R-squared:  -0.02642
F-statistic: 0.8327 on 2 and 11 DF,  p-value: 0.4605

Value of test-statistic is: -0.3263

Critical values for test statistics:
1pct 5pct 10pct
tau1 -2.66 -1.95 -1.6
```

#### 4.9.2. Execução Manual Arima

Avaliamos os gráficos de ACF e PACF para avaliar os parâmetros de Arima, consideramos possíveis  $p$  [1,3],  $d$  [1] e  $q$  [1,2].



Fizemos diversos testes, considerando os parâmetros acima, o melhor modelo que se apresentou foi o (1,1,1).

Esse teste apresentou o menor AIC, AICc e BIC na ordem de 400.

```
Series: cs_diff
ARIMA(1,1,1)

Coefficients:
      ar1      ma1
    -0.1444  -0.1892
s.e.      NaN      NaN

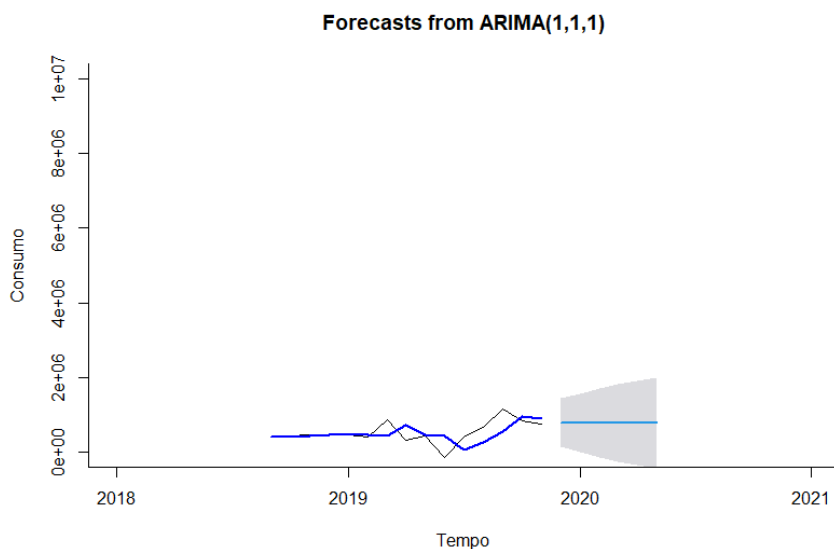
sigma^2 estimated as 1.12e+11: log likelihood=-196.94
AIC=399.87  AICc=402.27  BIC=401.79

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 34582.8 299399.3 213081.9 32.56986 57.49115 0.4511348 -0.02586558
warning message:
In sqrt(diag(x$var.coef)) : Nans produzidos
```

Porém, apresentou o pior MAPE de todos os modelos.

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1	Theil's U
Training set	34582.8	299399.3	213081.9	32.56986	57.49115	0.4511348	-0.02586558	NA
Test set	4046234.5	4190510.5	4046234.5	83.00647	83.00647	8.5666487	0.22687980	4.187041

Visualmente a série estacionária está tendendo ao centro do intervalo de confiança.



### 4.9.3. Execução Auto Arima

O Auto Arima selecionou a opção (0,0,0), porém ao avaliar o sumário já notamos uma piora no AIC, AICc e BIC.

```
Series: cs_diff
ARIMA(0,0,0) with non-zero mean

Coefficients:
    mean
    524360.74
s.e.    73302.75

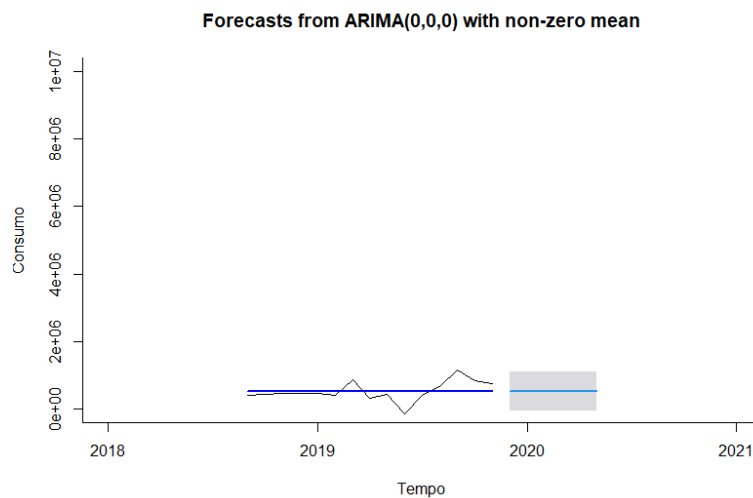
sigma^2 estimated as 8.635e+10: log likelihood=-209.63
AIC=423.26  AICC=424.26  BIC=424.68

Training set error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 9.70194e-11 283897.1 214408.2 28.17782 60.21092 0.4539429 0.3484231
```

Também se apresentou uma piora do MAPE, o pior cenário apresentado nesse trabalho.

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1	Theil's U
Training set	9.701940e-11	283897.1	214408.2	28.17782	60.21092	0.4539429	0.3484231	NA
Test set	4.300808e+06	4436515.7	4300808.4	88.56523	88.56523	9.1056300	0.2268889	4.432398

Visualmente o gráfico demonstra uma piora na precisão do modelo para explicar o passado e um menor intervalo para representar o futuro.



## 5. Seleção de Modelo

Listando todos os MAPEs obtidos na validação dos modelos:

Modelo	MAPE Teste
Naive	28.34677
Tendência Linear	22.071319
<b>Tendência Quadrático</b>	<b>14.75930</b>
Média Móvel	32.58837
Suavização Simples	28.47314
Suavização Tendência Aditiva	20.492674
Suavização Tendência Multiplicativa	26.97656
Suavização Automático	20.702683
Arima	83.00647
Auto Arima	88.56523

Para os dados analisados de consumo de serviços de Cloud, o melhor modelo obtido foi o de Tendência Quadrática, avaliando a performance do período de validação dos dados através dos MAPEs resultantes. Nesse momento analisando somente essa variável, pois ao longo do trabalho as demais características como: a análise de resíduos, assertividade do modelo e avaliação das hipóteses foram atendidas corretamente.

## 6. Conclusão

Nesse momento, estabeleceríamos o modelo de tendência quadrática como modelo de previsão, porém seguiríamos com reavaliações recorrentes por ser um produto novo, com pequeno histórico de vendas e ainda estabilizando seu comportamento de consumo pelos clientes.

Até o presente momento, esse produto não tem nenhuma característica de sazonalidade, mas também vamos acompanhar esse comportamento de consumo por um período mais longo.